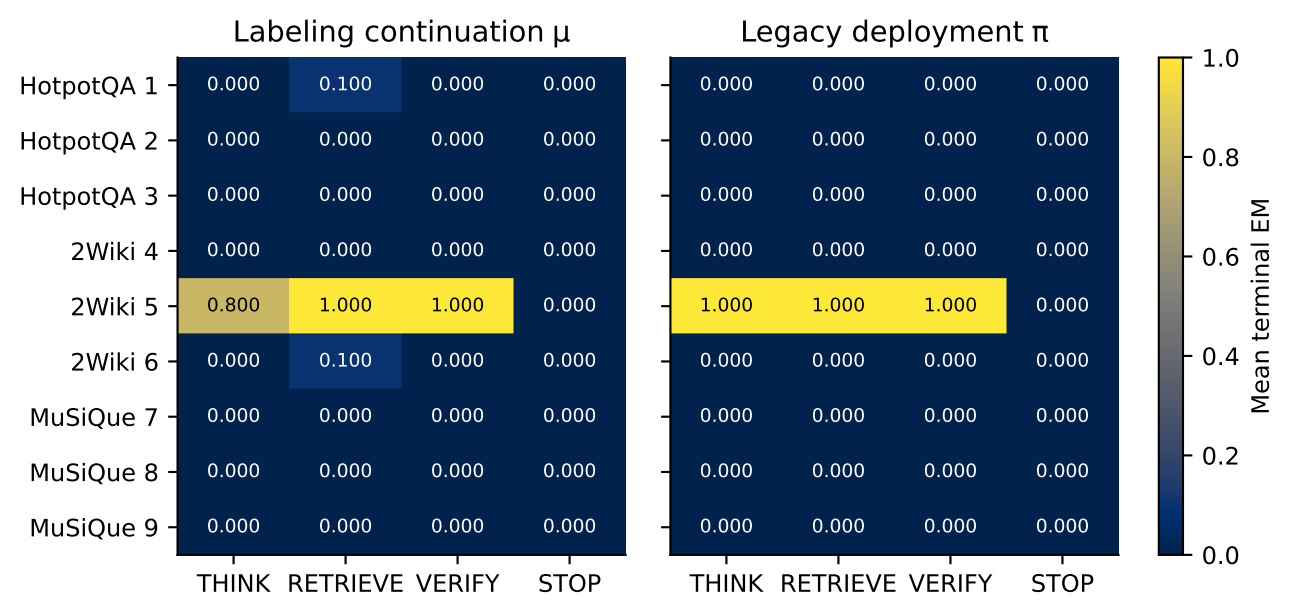
Labeling continuation μ
Legacy deployment π
HotpotQA 1
HotpotQA 2
HotpotQA 3
2Wiki 4
2Wiki 5
2Wiki 6
MuSiQue 7
MuSiQue 8
MuSiQue 9
0.000 0.100 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.800 1.000 1.000 0.000
0.000 0.100 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
1.000 1.000 1.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
0.000 0.000 0.000 0.000
THINK RETRIEVE VERIFY STOP
THINK RETRIEVE VERIFY STOP
Mean terminal EM
1.0
0.8
0.6
0.4
0.2
0.0